# 数据扩展与退化增强：实验结果分析

2026 年 11 月 13 日·English ·中文 PDF

扩展数据提高了 KEH 和 LAG 来源的青光眼图像排序表现，AIROGS 和 ODIR 来源的表现下降。50% 退化增强提高了合成失焦图像的排序表现，并减少误报，同时增加部分阳性漏诊。12 张真实低质量开发阳性图像在三个扩展方案下均被检出，退化增强在这组图像上没有额外检出。

本文承接同日的数据与方法审查和训练结果报告，进一步分析来源差异、实际采样次数、权重选择以及真实低质量图像的标签分布。这些分析为下一轮控制实验提供依据。

## 数据、模型与比较方法

四个方案均使用 EfficientNet-B0、相同初始化和随机种子 20261113，各完成 1,200 次有效优化更新。原数据方案使用 10,338 张训练图像；三个扩展方案使用 15,480 张。30% 和 50% 表示采样图像应用混合退化增强的概率。阳性保留各来源的定义，包括青光眼诊断和 AIROGS 的青光眼转诊标签，因此结果按来源分析。模型验证集含 2,046 张图像，其中阳性 823 张；规则开发集含 2,053 张，其中阳性 814 张。模型验证集用于选择权重和设定来源阈值，规则开发集用于拟定人工复核规则及本文的结果分析。最终测试将在模型和复核规则确定后执行。

训练报告记录的是验证指标最高时选中的权重：原数据、30% 退化和 50% 退化均选中第 1,200 次更新，扩展无退化选中第 300 次更新。本文主要使用四组第 1,200 次更新权重，使比较具有相同更新预算；选中权重的结果另存于分析数据。一轮训练表示完整遍历训练集，优化更新表示处理一个批次后调整模型参数，本轮预算按更新次数设定。

95% 区间通过 4,000 次配对自助重采样计算：每次抽取完整关联组，同一批组同时用于比较两个模型。关联组将已知双眼、同眼重拍或其他关联图像放在一起，以保留图像间的依赖关系；指标按图像计算。区间反映开发图像抽样的不确定性，本轮单个训练种子的随机性需由后续多种子实验评估。区间均为单项百分位区间，多来源比较采用逐项解释。来源配对差异表保留完整结果。

## 数据扩展带来的来源差异

AUROC 是受试者工作特征曲线下面积（area under the receiver operating characteristic curve）。直观地说，随机抽取一张阳性和一张阴性图像时，它表示模型给阳性更高分的概率，分数并列计一半。例如 AUROC 为 0.93，表示约 93% 的阳性—阴性配对能够正确排序；AUROC 为 0.5 相当于随机排序，为 1 表示完全区分。改变分类阈值，会得到不同的敏感度和误报率，这些点组成 ROC 曲线；AUROC 汇总整条曲线的排序能力，实际检出和误报数量则由所选阈值决定。下表按来源比较同一批开发原图，正值表示前一个方案更好，例如 +0.027 表示 AUROC 增加 0.027。

| 来源：图像 / 正例 / 关联组 | 扩展 - 原数据：AUROC 差及 95% 区间 | 50% 退化 - 扩展：AUROC 差及 95% 区间 |
|---|---|---|
| AIROGS: 773/380/772 | -0.0136 [-0.0239, -0.0040] | +0.0042 [-0.0011, +0.0100] |
| ODIR: 305/28/193 | -0.0397 [-0.0694, -0.0094] | +0.0089 [-0.0096, +0.0265] |
| Kaggle: 142/95/142 | -0.0058 [-0.0197, +0.0052] | -0.0054 [-0.0160, +0.0033] |
| LAG: 481/169/481 | +0.0425 [+0.0248, +0.0616] | -0.0058 [-0.0098, -0.0025] |
| KEH: 153/75/153 | +0.2706 [+0.1818, +0.3639] | +0.0034 [-0.0103, +0.0178] |
| BEH: 33/8/33 | -0.0400 [-0.1323, +0.0220] | +0.0400 [+0.0000, +0.1154] |
| FIVES: 27/13/27 | +0.0769 [-0.0056, +0.1975] | +0.0000 [-0.0706, +0.0659] |

KEH 的 AUROC 从 0.6627 升至 0.9333，LAG 从 0.9465 升至 0.9890，两项差异的 95% 区间均高于零。KEH 以视盘裁剪图为主，LAG 为完整眼底图，改善覆盖两种成像视野。AIROGS 和 ODIR 分别下降 0.0136 和 0.0397，两项区间均低于零。Kaggle、BEH、FIVES 的区间较宽，覆盖正负两种变化。

扩展无退化选中第 300 次更新权重时，AIROGS 相对原数据下降 0.0312；到第 1,200 次更新，降幅缩小至 0.0136。ODIR 的两项降幅分别为 0.0389 和 0.0397。因此，权重选择时间解释了部分 AIROGS 差异，ODIR 的下降在训练预算结束时仍存在。

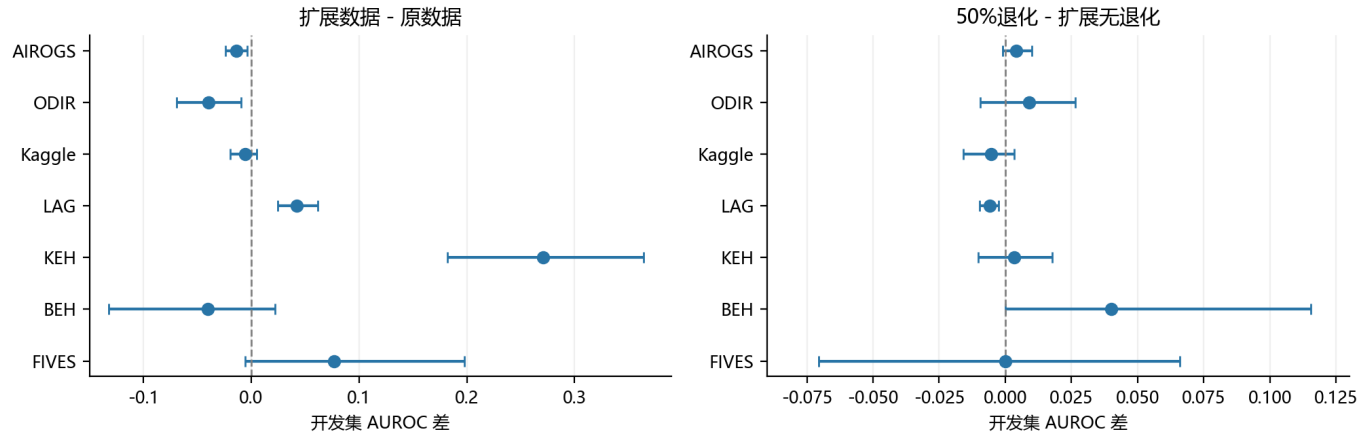



图 1: 第 1,200 次更新权重的来源 AUROC 配对差异

图 1 左侧比较扩展无退化与原数据，右侧比较 50% 退化与扩展无退化。圆点是 AUROC 差，横线是关联组重采样的 95% 区间，虚线是零差异。左右横轴范围不同，以便看清各自的变化。50% 退化在 LAG 原图上下降 0.0058，区间为 [−0.0098, −0.0025]；AIROGS、ODIR、KEH 的额外变化区间均覆盖零。

AUPRC 是精确率—召回率曲线下面积，关注阳性检出的精确率和覆盖程度，随来源的阳性比例变化，适合在同来源内比较模型。Brier 分数是预测概率与 0/1 标签之间的平均平方误差，越低表示概率预测越准确。

| 第 1,200 次更新，扩展 - 原数据 | AUPRC 差及 95% 区间 | Brier 差及 95% 区间 |
|---|---|---|
| AIROGS | -0.0123 [-0.0231, -0.0023] | +0.0230 [+0.0110, +0.0356] |
| ODIR | -0.1604 [-0.2920, +0.0104] | +0.0217 [+0.0027, +0.0412] |
| LAG | +0.0735 [+0.0404, +0.1118] | -0.0571 [-0.0811, -0.0330] |
| KEH | +0.2578 [+0.1561, +0.3600] | -0.1482 [-0.1998, -0.0973] |

KEH 和 LAG 的 AUPRC 提高、Brier 下降，AIROGS 的 AUPRC 下降、Brier 上升，与 AUROC 的方向一致。ODIR 的 Brier 上升，但 AUPRC 差异区间覆盖零。ODIR 的 305 张开发图像只有 193 个关联组，其中阳性组 19 个，这使阳性检出指标的区间较宽。

## 新增来源如何改变采样和权重选择

每次优化更新使用一批采样图像；同一张图像可在训练过程中出现多次。现有采样器为每张图像分配其 “来源与类别组合” 图像数的平方根倒数权重。一个组合内图像越多，其总采样权重越大，但增长慢于图像数。加入新来源后，旧来源分得的采样比例降低。

| 方案 | 原数据采样次数 / 不同原图 | 新增数据采样次数 / 不同原图 |
|---|---|---|
| 原数据 | 19,186/8,339 | 0/0 |
| 扩展数据 | 9,484/5,929 | 9,708/3,901 |
| 30% 退化 | 9,484/5,929 | 9,708/3,901 |
| 50% 退化 | 9,484/5,929 | 9,708/3,901 |

表中 “不同原图” 表示实际至少采样过一次的图像。原数据对照共采样 19,186 次，覆盖 8,339/10,338 张训练图像（80.7%）。扩展方案中，原数据采样 9,484 次，占 49.4%，覆盖 5,929 张原图（57.4%）；新增数据采样 9,708 次，占 50.6%，覆盖 3,901/5,142 张新增训练图像（75.9%）。三个扩展方案逐图采样次数完全相同，适合比较退化增强的影响。末尾不满批次使原数据与扩展方案的总采样次数相差 6 次。

新增图像最多重复 30 次，原数据对照最多重复 14 次。数据扩展同时改变了来源组成、原数据采样次数和重复频率；下一轮控制原数据采样配额，可以进一步检验这些因素对原来源表现的影响。

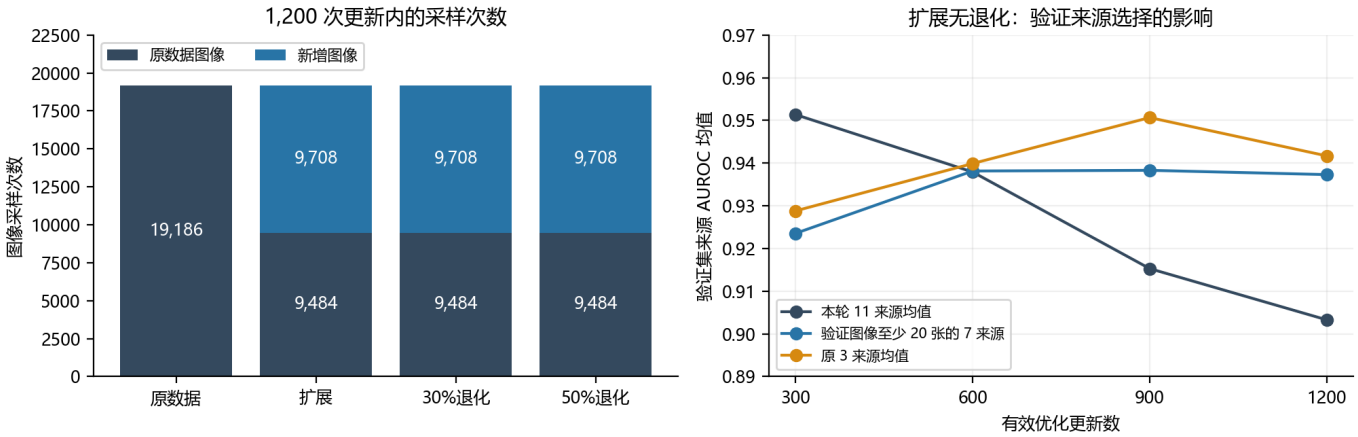



图 2: 实际图像采样次数与验证指标变化

图 2 左侧显示四组的原数据和新增数据采样次数；右侧显示扩展无退化方案在三种验证来源组合下的 AUROC 等权均值。本轮选择权重时使用 11 个同时包含阳性和阴性的验证来源。HRF、CRFO、Fundus-AVSeg、LES-AV 分别只有 4、6、3、2 张验证图像，合计 15 张，却占这个均值 4/11，即 36.4% 的权重。

扩展无退化从第 300 到 1,200 次更新，HRF AUROC 从 1.0 降至 0.5，使 11 来源均值下降 0.04545；该均值的总降幅为 0.04807。CRFO 另贡献 −0.01136，其他来源的改善抵消了部分下降。原数据对照中，CRFO 从 0.5 升至 1.0，贡献 +0.04545，而均值总升幅为 0.03241。少量验证图像对权重选择有较大影响。

若分析至少有 20 张验证图像的七个来源，扩展无退化的均值从 0.9235 升至 0.9373，最高点位于第 900 次更新；原三个来源的均值也在第 900 次更新最高。这是对已有验证日志的敏感性分析。第 600 和 900 次更新的完整权重未保存，因此开发集结果仍使用已保存的第 300 和 1,200 次权重。

## 退化增强在合成失焦下的效果

合成退化评估使用同一组 384 张开发原图，包括阳性 146 张、阴性 238 张，按图像标识的哈希固定选取。失焦半径以 512 像素眼底视野为参照取 2，并随实际视野缩放；曝光变体将亮度乘以 0.70。每张图像的原图与退化版本配对比较。下表使用第 1,200 次更新权重，以预测概率大于 0.5 判为阳性；该阈值用于本轮结果展示。

| 条件 / 指标 | 原数据 | 扩展数据 | 30% 退化 | 50% 退化 |
|---|---|---|---|---|
| 原图: AUROC | 0.9423 | 0.9690 | 0.9702 | 0.9688 |
| 原图: 漏诊 / 误报 | 30/16 | 23/15 | 21/13 | 23/14 |
| 失焦: AUROC | 0.9193 | 0.8894 | 0.9332 | 0.9449 |
| 失焦: 漏诊 / 误报 | 55/10 | 18/68 | 36/23 | 28/19 |
| 曝光 0.70: AUROC | 0.9382 | 0.9536 | 0.9611 | 0.9564 |
| 曝光 0.70: 漏诊 / 误报 | 39/13 | 21/23 | 26/17 | 29/18 |

失焦条件下，50% 退化相对扩展无退化的 AUROC 增加 0.0555 [0.0308, 0.0817]，AUPRC 增加 0.1019 [0.0511, 0.1592]，Brier 下降 0.0684 [0.0445, 0.0938]。误报从 68/238 降至 19/238，误报率下降 20.59 个百分点 [15.25, 26.03]；漏诊从 18/146 升至 28/146，漏诊率增加 6.85 个百分点 [0.71, 13.33]。排序改善与固定阈值下的漏诊—误报变化需要一起评价。

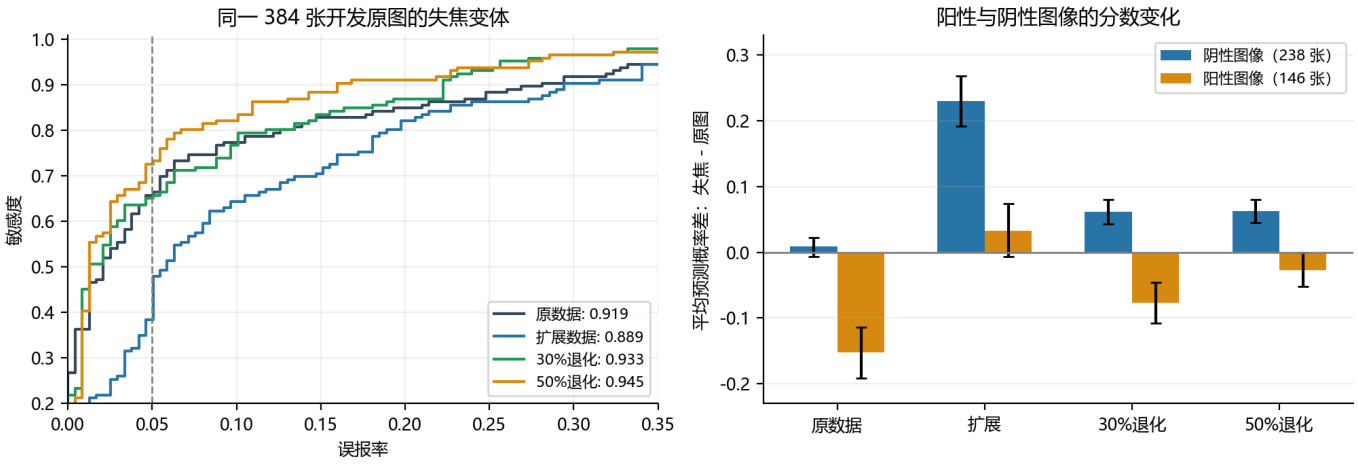



图 3: 合成失焦下的 ROC 曲线与预测概率变化

图 3 左侧的 ROC 曲线展示不同阈值对应的敏感度与误报率，图例同时标出 AUROC；右侧按真实标签显示失焦分数减去原图分数的平均差及 95% 区间。扩展无退化的阴性图像分数平均增加 0.2295，50% 退化只增加 0.0622。原数据对照的阳性分数平均下降 0.1523，50% 退化下降 0.0273。退化增强减轻了失焦对阳性和阴性分数的影响。

将同一退化子集上的特异度匹配到 95.4% 后，四组失焦敏感度分别为 65.8%、38.4%、65.1%、72.6%。这项探索性比较为每组、每种条件重新计算阈值，用来解释排序表现。来源内比较也显示改善：50% 退化在失焦 AIROGS 上的 AUROC 增加 0.0691 [0.0258, 0.1149]，在 LAG 上增加 0.0835 [0.0341, 0.1455]。

另一项比较固定每组从原始验证阴性图像设定的来源阈值，再用于原图与退化版本。验证集同时包含两类标签的七个来源贡献 356 张压力评估图像，其中阳性 139 张、阴性 217 张；其余 28 张图像所在的小来源缺少两类验证标签。下表依次列出漏诊数 / 误报数。

| 条件：验证阈值固定 | 原数据 | 扩展数据 | 30% 退化 | 50% 退化 |
|---|---|---|---|---|
| 原图 | 34/11 | 27/7 | 30/10 | 30/11 |
| 失焦 | 63/10 | 28/47 | 45/16 | 40/10 |
| 曝光 0.70 | 38/8 | 25/15 | 30/13 | 35/13 |

固定验证阈值后，50% 退化相对扩展无退化的失焦误报从 47 降至 10，漏诊从 28 升至 40。曝光乘以 0.70 时，AUROC 差为 +0.0028 [−0.0078, 0.0138]，漏诊从 25 升至 35。当前增强收益主要集中在失焦；下一轮单独比较失焦增强与混合增强，可以确定有效的退化类型和强度。

## 真实低质量图像的检出与标签分布

真实低质量开发图像来自 FIVES 7 张、MSHF 5 张，均为阳性，属于 12 个不同关联组。在阈值 0.5 下，原数据对照检出 7/12，三个扩展方案均检出 12/12。12/12 对应的精确二项 95% 区间为 73.5%–100%；FIVES 和 MSHF 分别为 59.0%–100% 和 47.8%–100%。新增检出为 FIVES 2 张、MSHF 3 张，无新增漏诊；比较同图检出变化的 McNemar 精确检验双侧 p=0.0625。区间说明这组图像的检出比例仍存在较大的抽样不确定性。

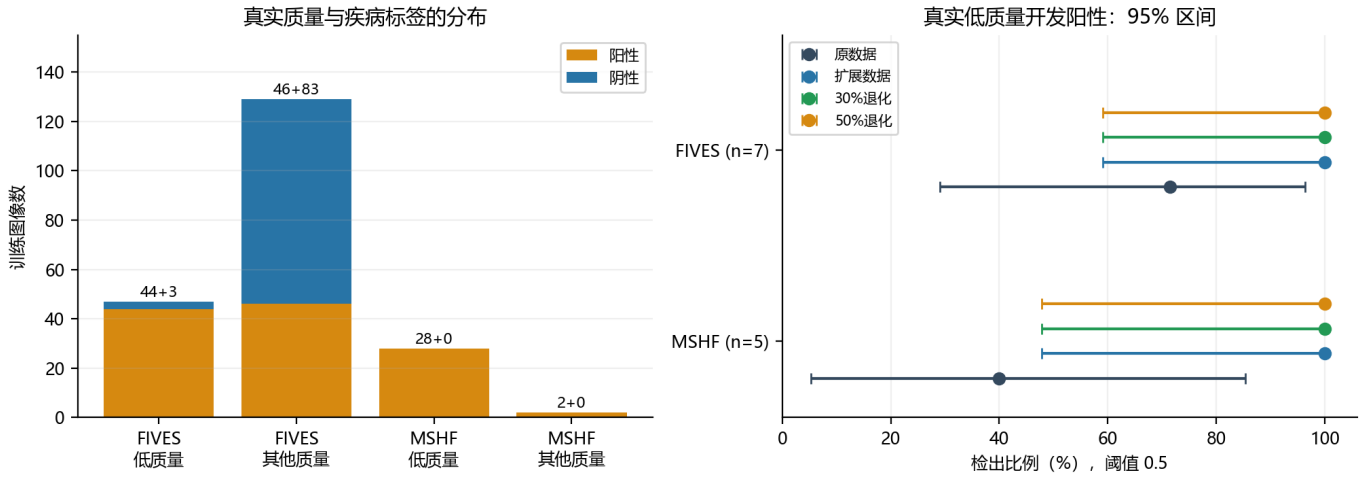



图 4: 真实质量与疾病标签的训练分布以及开发阳性检出比例

图 4 左侧按来源和原始质量标注显示训练图像数，柱顶数字依次为阳性数 + 阴性数；右侧显示同来源真实低质量开发阳性的检出比例与精确二项 95% 区间。FIVES 以至少一个质量维度标为差定义低质量，MSHF 使用总体质量标注。“其他质量” 包含该来源剩余质量档次，两个来源保留各自的标注标准。

FIVES 的 47 张低质量训练图像中，阳性 44 张、阴性 3 张；其他 129 张中，阳性 46 张、阴性 83 张。MSHF 的 28 张低质量和 2 张其他质量训练图像全部为阳性。实际训练采样中，这两个来源的真实低质量阳性出现 413 次，阴性仅 10 次。质量与疾病标签高度关联，因此下一轮应加入同来源真实低质量阴性，比较质量平衡采样，区分来源、质量线索与疾病特征的作用。

固定验证来源阈值后，扩展无退化和 50% 退化均检出 FIVES 的 7/7 张低质量阳性。对比这两个方案，FIVES 全部 13 张开发阳性的敏感度从 76.9% 升至 92.3%，14 张阴性的特异度从 100% 降至 78.6%。阈值来自 14 张验证阴性，并取其最高分数，后续需要更多阴性图像来稳定阈值。MSHF 当前仅有阳性图像，其来源内特异度需在补充阴性后评估。

## 下一轮控制实验建议

建议设置一个原数据对照，以及四个扩展方案，分别组合两种采样方法（现有方法、原数据 65% 采样配额）和两种增强设置(无退化、50% 混合退化)。每组使用三个共同种子、相同初始化条件和 2,400 次有效更新。按每批 16 张计算，65% 配额预计提供 24,960 次原数据采样，高于本轮原数据对照的 19,186 次；来源内继续使用平方根倒数权重。在相同预算下比较采样与增强，并保存第 1,200 和 2,400 次更新权重，评估继续训练的影响。

预先指定 AIROGS、ODIR、Kaggle、LAG、KEH 五来源 AUROC 的等权均值作为主要权重选择指标，同时报告原三个来源均值、各来源敏感度和特异度。BEH、FIVES 和更小来源作为补充评估。每 300 次更新保存完整权重与预测，分别报告开发图像重采样区间和跨训练种子的变化。

随后在相同应用概率、采样序列和更新预算下，比较单独失焦与混合退化增强。评估固定验证阈值下的漏诊、误报、真实低质量阴性表现，以及原图 AUROC 和 Brier。依据预先约定的原来源表现、质量分层结果和复核工作量选择模型与阈值，再执行最终测试。上述方案是下一轮建议，尚未运行。

## 分析产物与复现

训练结果 ·数据审计 ·退化审计 ·图像采样记录 ·图表数据 ·分析程序 ·报告生成程序

在训练环境运行分析程序的 `--extract-draws` 选项，提取检查点内的逐图采样计数；随后在文档环境运行分析程序和报告生成程序。分析核对四组的图像标识、标签、来源、关联组与冻结清单，并记录输入文件的 SHA256。统计测试覆盖并列分数处理、关联组重采样和同图配对检查。