新数据集与眼底图像退化实验：进度总览

2026 年 11 月 13 日·English ·PDF

项目已完成本轮公开数据审查、新增图像的标签和关联核验、训练数据划分，以及四组青光眼分类实验。扩展数据显著改善了 KEH 和 LAG 开发集的图像排序；在合成失焦条件下，50% 退化增强提高了排序表现并减少误报，同时增加了阈值 0.5 下的阳性漏诊。下一轮工作重点是保持原来源的训练采样量、改进模型选择规则，并补充真实低质量阴性病例。分类阈值、质量引导的人工复核规则及最终测试尚待完成。

本目录按实验顺序组织为数据与方法审查、训练结果和统计分析。三份报告记录同一天工作的不同阶段。本总览以完成训练后的数据版本和第 1,200 次更新权重为准。

数据准备完成了什么

公开来源审查覆盖 45 个数据集或数据集系列。逐图核验后，新增池纳入 9,070 张图像，包括 3,446 张阳性图像；另有 204 张疑似图像单列记录。阳性标签保留各来源的原始定义，其中 3,443 张为来源定义的青光眼阳性，3 张为 AIROGS 的转诊阳性。视盘裁剪图与完整眼底照片分别标记。

新增池经关联分组后，与修正后的原数据组成 24,491 张图像的疾病训练与评价清单。原训练与验证部分中，18 张关联官方 EyeQ 测试图像的照片已移除；规则开发部分沿用身份关联核查后的 1,220 张原图。

用途	修正后原数据	新增数据	合计
疾病模型训练	10,338	5,142	15,480
模型验证	1,188	858	2,046
人工复核规则开发	1,220	833	2,053
内部及新增保留测试	1,233	2,237	3,470
ACRIMA 外部测试	705	0	705
HYGD 外部测试	737	0	737

训练集含 6,405 张阳性，模型验证集含 823 张阳性，规则开发集含 814 张阳性。已知患者和确认的关联图像按组分配用途。PAPILA 整个纳入来源用于保留测试，FIVES 和 Fundus-AVSeg 的官方测试角色保留。全部 24,491 张图像通过文件哈希及完整 RGB 解码核验。

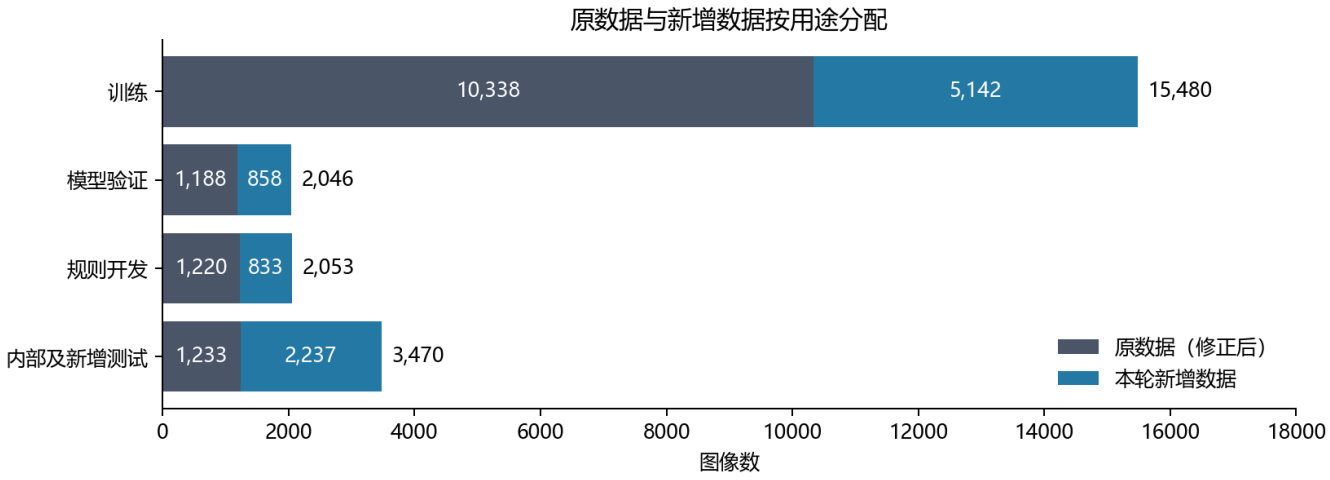


图 1: 原数据和新增图像按用途分配

图 1 显示四项主要用途的数据组成；数字为原图数量。新增池的 5,142 张图像进入训练，其余进入模型验证、规则开发或保留测试。ACRIMA 和 HYGD 合计 1,442 张外部测试图另列于表中。

本轮实验如何比较

四组均使用 EfficientNet-B0、相同初始化和随机种子 20261113，每批最多 16 张图像，各完成 1,200 次优化更新。原数据组使用修正后的 10,338 张训练图像，其余三组使用 15,480 张。扩展数据分别配合 0%、30% 和 50% 的混合退化应用概率，退化包括照明不均、失焦和散射。质量模型的监督目标沿用原图，退化增强用于疾病模型训练。

模型每 300 次更新在共同的 2,046 张模型验证图像上评价。原选模规则对 11 个含正负两类的来源等权平均 AUROC。原数据、30% 和 50% 退化组的选中权重均来自第 1,200 次更新，扩展无退化组来自第 300 次更新。下面统一比较第 1,200 次更新，便于判断相同训练预算下的差异。

已观察到的结果

AUROC 的全称是 “受试者工作特征曲线下面积”。模型输出疾病分数，改变判为阳性的分数阈值，可以得到一系列敏感度（检出的阳性比例）和误报率（被判为阳性的阴性比例）；ROC 曲线展示两者的关系，AUROC 是曲线下的面积。

它也可以理解为：随机抽取一张阳性和一张阴性图像，模型给阳性更高分的概率，并列分数计一半。例如 AUROC 为 0.93 表示这一排序概率约为 93%；0.5 相当于随机排序，1.0 表示完全区分。实际漏诊和误报需在选定阈值下另行评价。下表来自同一规则开发集的原图，各来源独立计算。

来源	原数据	扩展数据	30% 退化	50% 退化
AIROGS	0.9687	0.9551	0.9583	0.9593
ODIR	0.9712	0.9315	0.9281	0.9404
LAG	0.9465	0.9890	0.9844	0.9832
KEH	0.6627	0.9333	0.9321	0.9368

各来源开发图像数 / 阳性数分别为 AIROGS 773 / 380、ODIR 305 / 28、LAG 481 / 169、KEH 153 / 75。

扩展相对原数据的 AUROC 差，在 KEH 为 +0.2706，在 LAG 为 +0.0425；按关联组进行 4,000 次配对重采样所得的 95% 区间分别为 [0.1818, 0.3639] 和 [0.0248, 0.0616]。AIROGS 和 ODIR 分别下降 0.0136 和 0.0397，对应区间均低于零。这些区间表示开发病例抽样的不确定性；本轮使用一个训练种子。

压力评价对固定的 384 张规则开发原图生成失焦和曝光降低变体，包括 146 张阳性和 238 张阴性。50% 退化相对扩展无退化，在失焦条件下的 AUROC 从 0.8894 提高到 0.9449；阈值 0.5 下误报由 68/238 降至 19/238，漏诊由 18/146 升至 28/146。固定模型验证集设定的来源阈值后，误报减少与漏诊增加的方向一致。

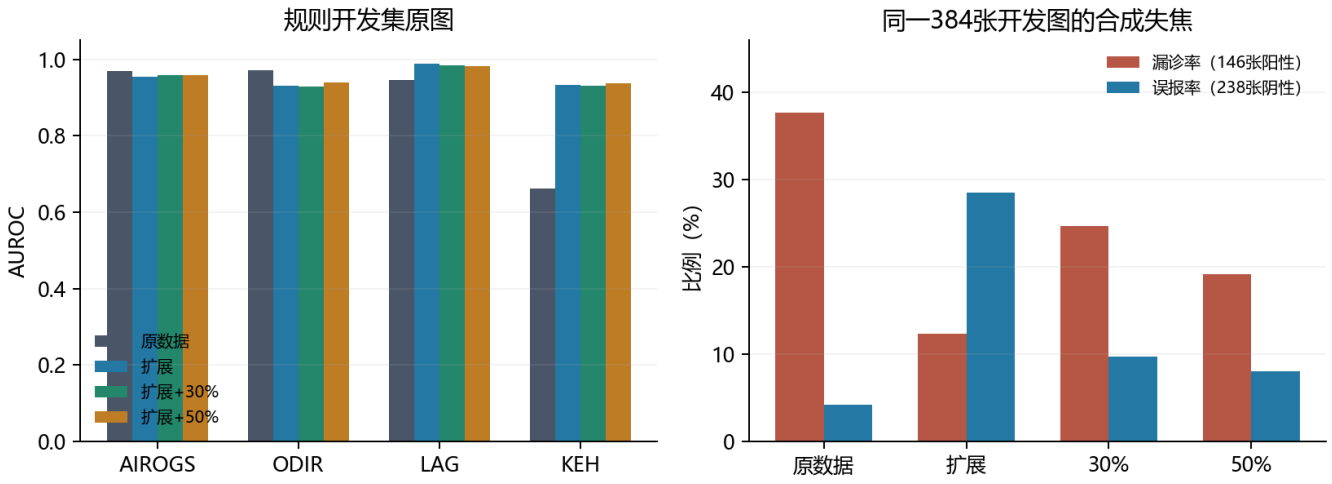


图 2: 第 1200 次更新的来源排序与合成失焦结果

图 2 左侧展示四个来源的原图 AUROC，右侧展示同一失焦开发子集在阈值 0.5 下的漏诊率和误报率。右侧两项比例分别以阳性和阴性图像数为分母。退化增强的作用需同时结合排序、漏诊和误报评价。

真实低质量开发病例为 FIVES 的 7 张和 MSHF 的 5 张阳性图像。在阈值 0.5 下，原数据组检出 7/12，三个扩展组均检出 12/12；12/12 的二项分布 95% 区间为 73.5%–100%。该子集全部为阳性，且三个扩展组的检出数一致，因此本轮的真实低质量检出改善主要体现在数据扩展。后续需结合相同来源的阴性图像评价误报。

疾病分数与质量分数的分布

2026 年 11 月 14 日补充：下面分别展示完整的规则开发集和模型验证集，共 4,099 张原图，包括本轮新增图像。每张图均匹配 50% 混合退化组第 1,200 次更新的疾病分数 p，以及此前 FTHNet 蒸馏质量学生的原始回归分数 q。q 越高表示预测质量越好，并非人工质量等级或已校准概率。模型验证集已用于权重选择，规则开发集用于研究复核边界；两者分别展示，不作为独立测试结果。

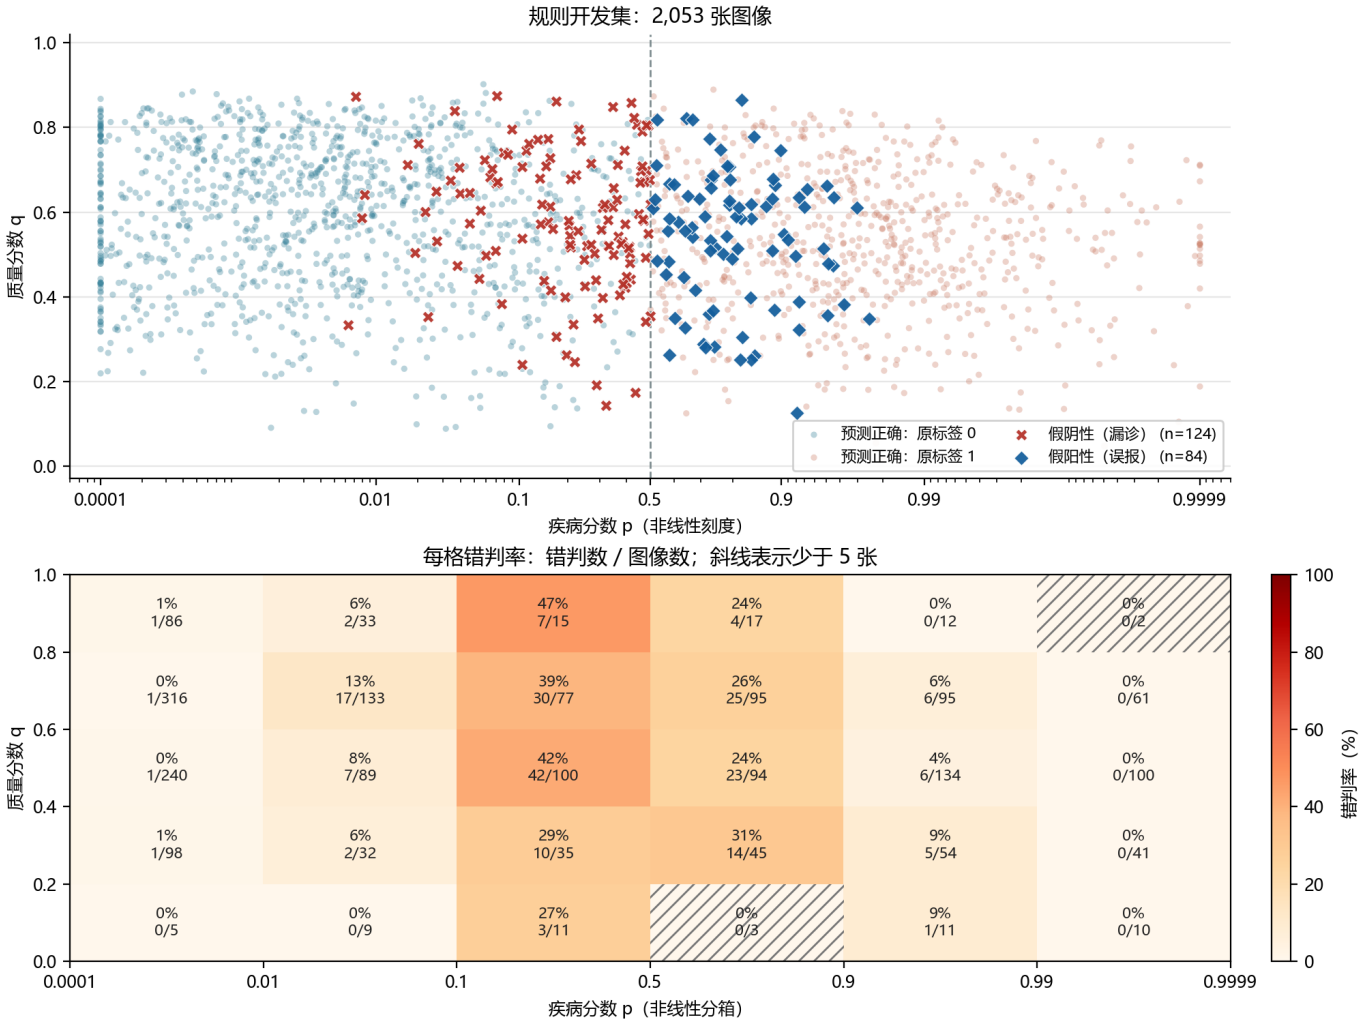


图 3: 规则开发集的错判分布和错判率

图 3 上方的浅色圆点表示预测正确的图像，红色叉号为假阴性（漏诊），蓝色菱形为假阳性（误报）。横轴 p 使用非线性刻度，纵轴为 q；小于 0.0001 或大于 0.9999 的 p 在显示时截到这两个边界。虚线是示例阈值 0.5。规则开发集共 2,053 张图，其中 814 张阳性；按该阈值有 124/814 张阳性漏诊，84/1,239 张阴性误报。

下方热力图按 p、q 分箱显示错判率：每格颜色和百分比是该格错判数除以该格总图像数，文字同时给出错判数 / 总数。空格无图像；斜线标记少于 5 张的格子，其比例很不稳定。热力图中的 p 分箱边界与上图刻度对应，但各格等宽，不能将水平距离当作分数差。

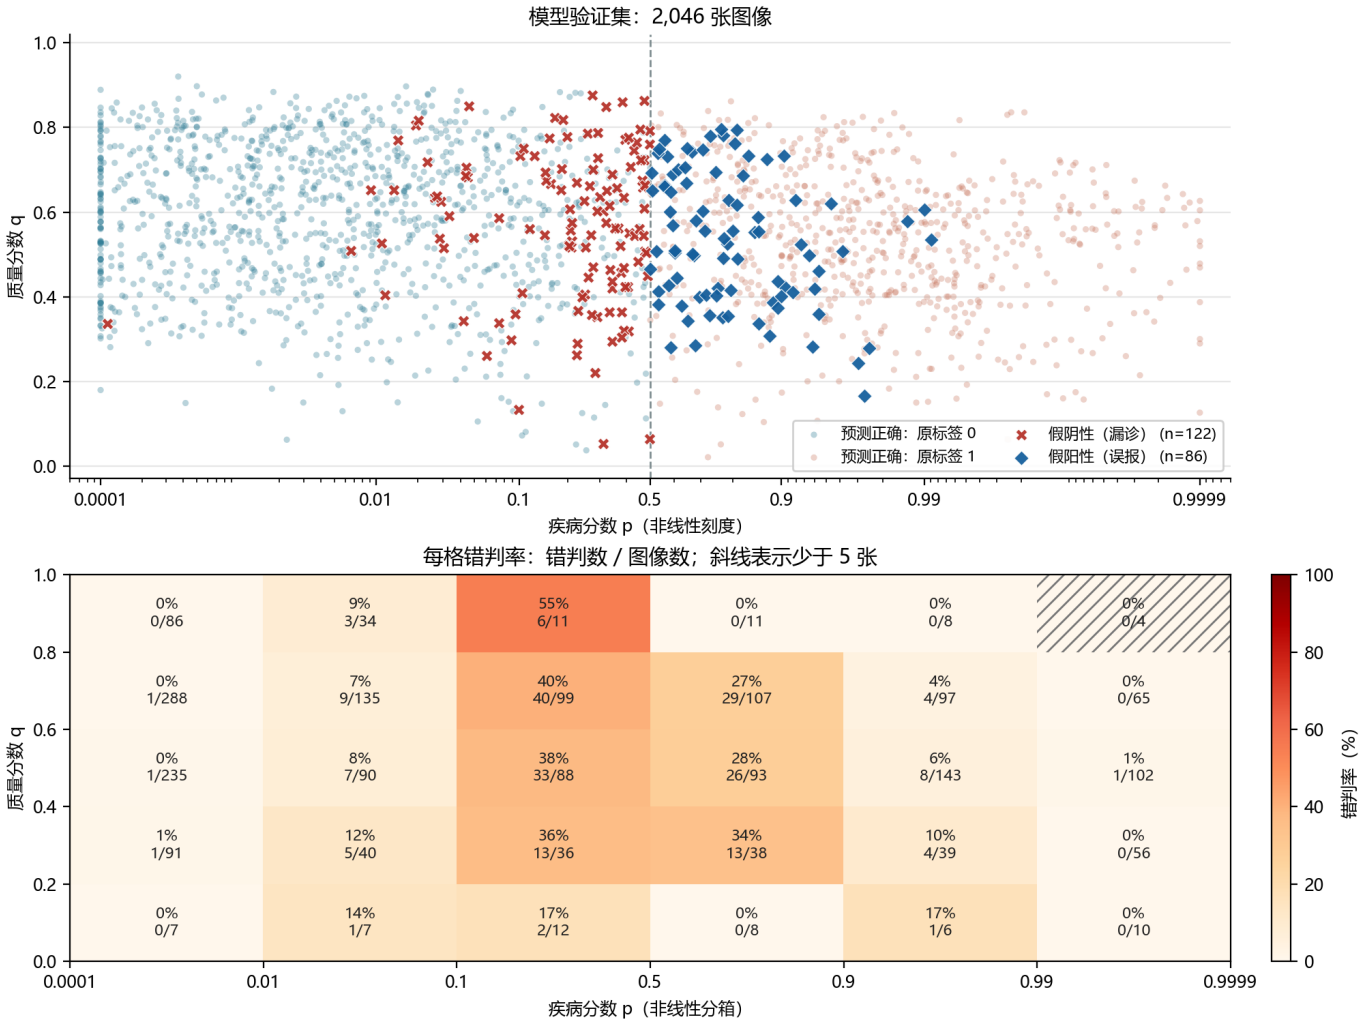


图 4：模型验证集的错判分布和错判率

图 4 为同一模型在 2,046 张模型验证图上的分布，其中 823 张阳性；示例阈值下有 122/823 张阳性漏诊、86/1,223 张阴性误报。这些图用于探索，尚未确定临床阈值或复核灰区。最终保留测试集仍待规则锁定后评价。逐格计数和输入指纹见图表数据，生成方法见绘图程序和质量分数推理程序。

分析指出的下一步

扩大训练池后，原来源图像的累计采样次数由 19,186 降为 9,484；三个扩展组使用相同的图像采样序列。新增来源适应与原来源采样量变化同时发生，下一轮将用原来源采样配额区分两者作用。

现有选模平均值中，HRF、CRFO、Fundus-AVSeg 和 LES-AV 合计只有 15 张验证图像，却占四个等权来源，即 36.4% 的权重。这使少数图像的排序变化明显影响权重选择。下一轮拟以 AIROGS、ODIR、Kaggle、LAG 和 KEH 为主要选模来源，保存每次验证权重，并采用三个共同随机种子与 2,400 次更新预算。

真实低质量训练图像的质量标记与疾病类别高度相关。后续还需补充真实低质量阴性图像，分别比较失焦增强与混合退化，并在模型验证数据上设定分类阈值。完成这些比较后，选择疾病模型和质量模型、开发人工复核规则，固定规则再评价保留测试集。详细实验安排见统计分析与下一步清单。

与此前训练的关系及证据

此前 `formal_v3` 两套疾病模型、原质量模型和 `eyeq_quality_v1` 均已完成 20 轮训练。11 月 12 日报告记录的疾病权重选自第 16 和 18 轮，在 AIROGS 模型验证集上的 AUROC 为 0.9766 和 0.9831；EyeQ 质量模型选中第 17 轮权重，

在 117 张 EyeQ 验证图像上的三档 macro-F1 为 0.811。本轮固定 1,200 次更新实验采用新的数据清单，评价集也已扩展；两轮结果分别解释。

可核查的证据包括冻结清单核验、第 1,200 次更新结果、配对统计及报告构建程序。逐图预测、完整训练日志、数据文件与模型权重位于本地数据和运行目录；报告中的汇总表、图和统计结果随仓库保存。