数据整合、退化算法审计与新一轮训练结果

2026 年 11 月 13 日·Eye Sentinel

English ·中文 PDF ·当日进度总览

本轮完成了什么

本报告承接同日的数据与退化方法审查，记录审计后的数据划分、四组训练和开发集评价；实验分析进一步解释来源差异、训练采样和选模的影响。

新增数据与原疾病数据合并为固定版本 expanded_20261113。四组 EfficientNet-B0 使用相同的 ImageNet 预训练初始化，分别比较原数据、扩展数据、扩展数据加 30% 退化和扩展数据加 50% 退化。每组完成 1,200 次优化更新，即 1,200 次实际参数调整；配置中的 20 轮是训练上限，本轮按更新次数结束。模型验证集用于选择权重，规则开发集用于分析表现和后续设计人工复核规则，两者用途分开。四组均使用随机种子 20261113。

AUROC 的全称是受试者工作特征曲线下面积。随机抽取一张阳性和一张阴性照片时，它表示模型给阳性更高分的概率，并列分数计一半。0.5 对应随机排序，1 对应完全区分；例如 0.93 表示约 93% 的阳性 / 阴性配对中阳性分数更高。具体筛查阈值下的漏诊和误报另行评价。

下面首先报告各组由模型验证集选中的权重：扩展无退化组为第 300 次更新，其余组为第 1,200 次更新。相同第 1,200 次更新的比较见 “模型选择的补充检查”，也用于当日总览和实验分析。

在 305 张 ODIR 规则开发图像（28 张正例）上，原数据与扩展数据方案的 AUROC 分别为 0.9712 和 0.9323；30% 和 50% 退化方案分别为 0.9281 和 0.9404。在 12 张真实低质量正例上，以 0.5 为展示阈值，四组漏诊数依次为 5, 0, 0, 0。这组结果表明，扩展数据提高了这 12 张低质量阳性的检出，同时降低了 ODIR 原图的排序表现。下文分别报告来源结果、漏诊与误报，以解释这两种变化。

在 153 张 KEH 视盘裁剪开发图像（75 张正例）上，四组 AUROC 依次为 0.6627, 0.9212, 0.9321, 0.9368。KEH 图像主要是视盘局部裁剪，与完整眼底照片有不同的成像范围。ODIR 的 28 张阳性照片属于 19 个已确认阳性关联组；一组内的双眼或关联图像在统计时共同处理。

数据整合和本次新增发现

统一疾病清单共有 24,491 张图像。文件 SHA256 用于核对图像内容是否变化；完整 RGB 解码检查确认图像可以读取。全部图像通过检查，新增 9,070 张与审查阶段记录的原始像素一致。按患者、同眼、同图变体及已确认跨来源关联合并分组后，关联组跨用途和跨用途相同 RGB 像素均为零。386 个已知患者标识均分配到单一用途。缺少患者标识的来源按已确认图像关系分组，所记录的关联组数是图像分组数。

独立重建关联图发现，原疾病数据中有 18 张图像与官方 EyeQ 测试组关联。本次从新版本排除 16 张训练图和 2 张模型验证图，并落实 12 张原规则开发图的既有修复。这 18 张图的移除同时应用于原数据对照和三个扩展组。历史模型在移除前训练；涉及这些 EyeQ 组的后续评价使用本轮模型。

用途	原数据图像 / 正例	新增图像 / 正例	合计图像 / 正例
训练	10,338 / 4,409	5,142 / 1,996	15,480 / 6,405
模型验证	1,188 / 487	858 / 336	2,046 / 823
规则开发	1,220 / 503	833 / 311	2,053 / 814
内部及新增保留测试	1,233 / 489	2,237 / 803	3,470 / 1,292

另保留 ACRIMA 的 705 张、396 张正例和 HYGD 的 737 张、540 张正例。PAPILA 全来源 420 张（87 张正例，来自 47 名已知阳性患者）纳入保留测试，105 张官方测试图沿整组传播为测试用途。204 张疑似图单独保存，疾病二分类监督使用有明确阳性或阴性标签的图像。LAG、GRAPE、FIVES、Fundus-AVSeg 和 MSHF 按已确认关联联合分组。KEH 保留视盘裁剪域说明；RG 转诊标签与各来源临床诊断标签保持分列。

真实低质量正例分别保留在训练 72 张、模型验证 12 张、规则开发 12 张、测试 50 张。FIVES 按至少一个官方质量维度差定义，MSHF 按官方总体质量编码 0 定义，两者不合并成同一种质量标注。规则开发的 12 张是 FIVES 7 张和 MSHF 5 张。

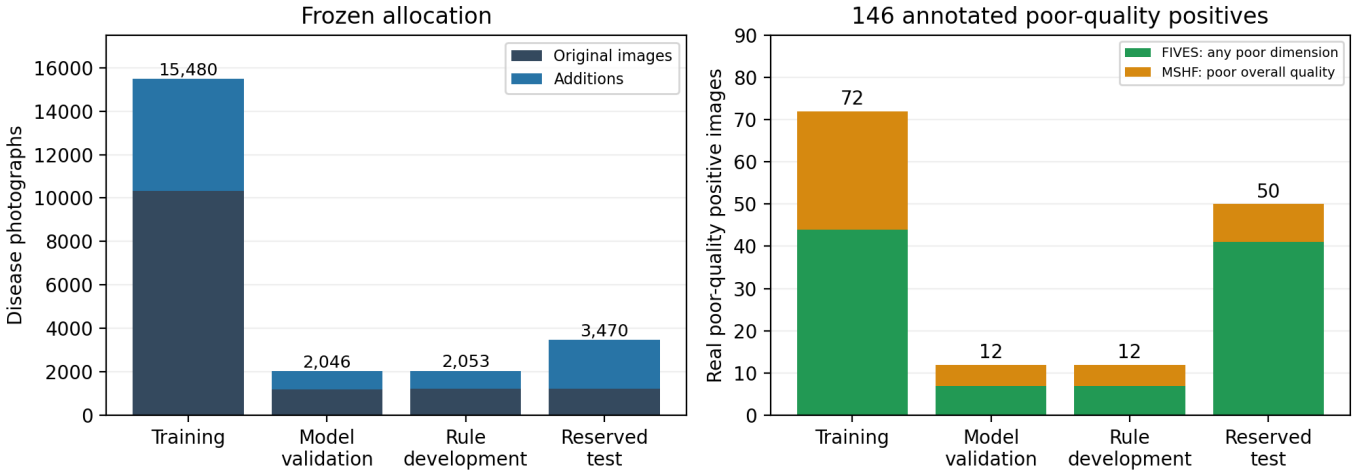


图 1: 冻结数据划分与真实低质量阳性分布

图 1 左侧按用途区分原数据和新增数据，合计包含训练、验证、开发和内部及新增保留测试；ACRIMA 和 HYGD 的外部测试单列于正文。右侧显示 146 张真实低质量阳性按用途和来源的分布。FIVES 与 MSHF 采用各自的官方质量定义。

退化算法与作者模型

已下载 CoFe-Net、ArcNet、FD3、Catintell 和 CUNSB-RFIE 五个固定提交版本，核查压缩包完整性、代码、许可和权重。CUNSB-RFIE 的 G、D、E、F 四份权重均可用受限权重加载方式读取，张量均为有限值；G 严格匹配作者 DSCNet，并完成一次 320×320 CPU 前向运行。这次运行核实了权重和作者代码的相容性。作者网络用于图像恢复，本轮疾病训练的退化图则由项目实现的成像模拟生成；两者是不同处理步骤。

退化增强在疾病图补边并缩放到 320×320 后、ImageNet 标准化前施加。每次等概率选择照明变化、失焦或轻度散射中的一种；失焦可附带轻噪声或 JPEG 压缩。散射通过平滑亮度混合降低局部对比度。模糊大小按有效眼底视野直径换算，曝光范围 0.72–1.12，512 像素视野参考模糊半径 0.5–2.0，散射透明度 0.03–0.10。图像标识、轮次和随机种子决定参数；保存的参数可重新生成相同图像，原始黑边保持原值。退化概率与疾病标签无关。

18 对 HRF 同眼重拍及 120 对 Real Fundus 的描述性比对显示，真实低 / 高质量绿通道 Laplacian 方差比中位数分别约 0.516 和 0.101，而固定温和失焦例约 0.805 和 0.719。这一方差描述边缘和细节的变化，也受噪声、图像对齐和内容影响；本次比对用于说明训练退化的强度。对质量模型的监督仍使用原图及其教师质量分数或人工质量等级，合成退化只用于疾病训练。

训练预算、采样和模型选择

四组共享清单、验证角色、种子 20261113、320 像素输入、batch 16、AdamW 学习率 0.0001 和相同更新预算。原数据组只过滤训练来源，不改变验证集。每张图的抽样权重为其来源、类别组合图像数的平方根倒数；图像数较少的组合因此获得更高的单图抽样概率。四组使用同一规则，扩展组加入来源后，各原来源获得的训练采样次数会改变。累计抽到的不同原始图像依次为 8339, 9830, 9830, 9830，这些计数与生成版本数分开保存。实际退化抽样比例为 30.1% 和 50.1%。

每 300 次更新验证一次，按 11 个同时有正负例的来源各自 AUROC 的平均值选权重。来源 AUROC 先分别计算，再等权平均。恢复训练和多进程加载的一致性核验见配套审计记录。

方案	训练图像	选中更新数	验证来源平均 AUROC	真实低质量正例漏诊
原数据	10,338	1200	0.9235	5/12
扩展数据	15,480	300	0.9513	0/12
扩展 + 30% 退化	15,480	1200	0.9622	0/12
扩展 + 50% 退化	15,480	1200	0.9632	0/12

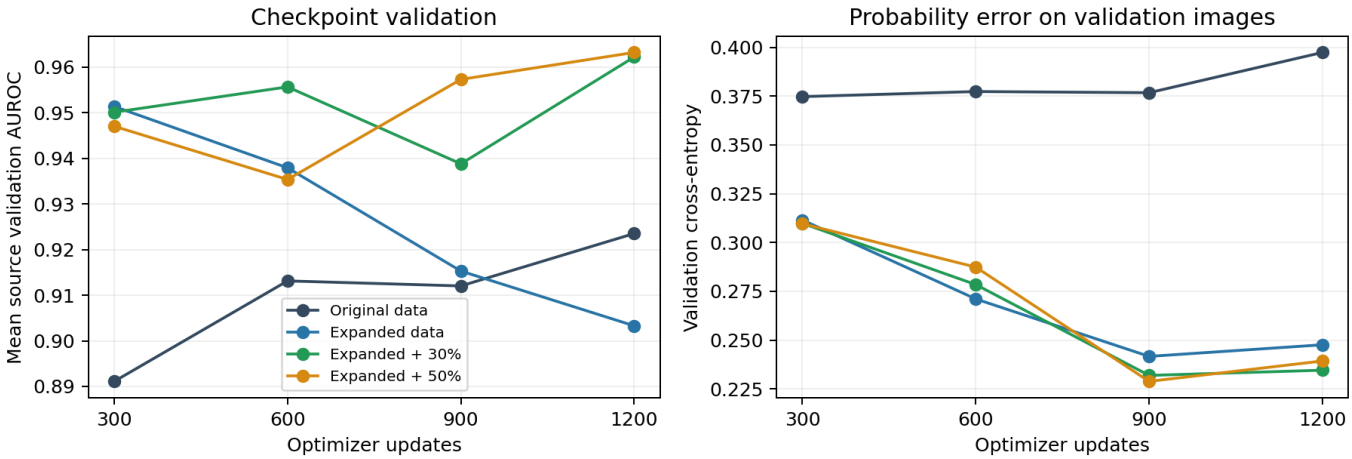


图 2: 相同更新预算下的验证结果

图 2 左侧为来源 AUROC 平均值，右侧为全验证图像的交叉熵，即模型为错误答案给出高置信度时产生的概率误差。曲线节点是 300、600、900 和 1,200 次更新，表中权重选自这些节点，扩展无退化组选中第 300 次更新，其余组选中第 1,200 次更新。

规则开发图像上的实际表现

下表使用每组已选权重，在相同原图上计算来源 AUROC。规则开发集用于本轮训练后的分析。完整结果还包括 AUPRC（精确率与召回率曲线下面积）、Brier 分数（预测概率与 0 / 1 标签的平均平方误差）及校准误差。AUPRC 受阳性比例影响，适合同一来源内比较；Brier 分数越低，概率误差越小。

来源（开发图像 / 正例）	原数据	扩展数据	30% 退化	50% 退化
AIROGS (773/380)	0.9687	0.9374	0.9583	0.9593
ODIR (305/28)	0.9712	0.9323	0.9281	0.9404
Kaggle (142/95)	0.9830	0.9698	0.9742	0.9718
LAG (481/169)	0.9465	0.9750	0.9844	0.9832
KEH (153/75)	0.6627	0.9212	0.9321	0.9368
BEH (33/8)	0.9100	0.9050	0.8900	0.9100
FIVES (27/13)	0.8736	0.9341	0.9560	0.9505

各组另按本来源验证阴性分数的第 95 百分位确定阈值，严格高于阈值才判为阳性。下表报告这些阈值在规则开发集上的敏感度和特异度，便于区分正例检出改善与整体分数上移；95% 是验证集上的目标，表中开发集特异度由新的病例分数决定。FIVES 只有 14 张验证阴性，因此该规则在验证集选择最大阴性分数，达到 100% 验证特异度。

来源	原数据：敏感度 / 特异度	扩展数据	30% 退化	50% 退化
ODIR	71.4% / 96.4%	42.9% / 97.1%	53.6% / 96.0%	53.6% / 96.4%
AIROGS	84.2% / 93.6%	71.3% / 93.9%	78.2% / 94.1%	76.3% / 94.9%
FIVES	61.5% / 92.9%	61.5% / 100.0%	76.9% / 92.9%	92.3% / 78.6%

MSHF 入选 49 张图全部为正例，没有同来源阴性可估计特异度。MSHF 结果因此报告阳性检出；FIVES 同时报告阳性检出和阴性误报。

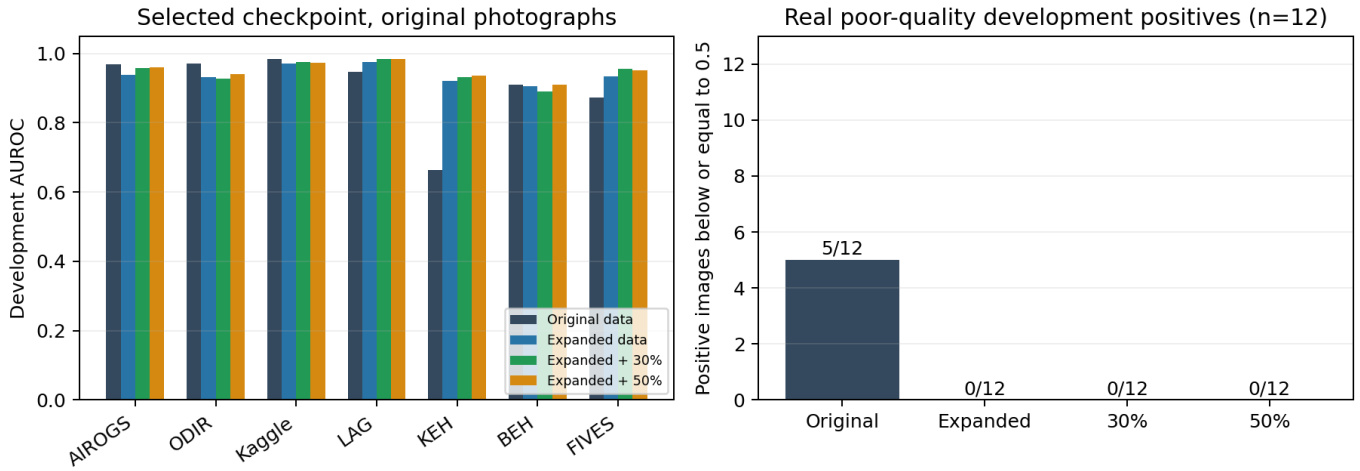


图 3: 原图排序和真实低质量正例漏诊

图 3 左侧比较七个主要来源的排序表现，右侧给出 12 张真实低质量正例的漏诊数量。0.5 用于统一展示，来源验证阈值的结果见前表。12 张低质量阳性由 FIVES 7 张和 MSHF 5 张组成，合计数描述这组固定开发照片。项目分类阈值及人工复核规则将在后续开发中确定。

对照（后者减前者）	敏感度变化（百分点）	关联组重抽样 95% 区间
扩展数据 − 原数据	+41.7	[+16.7, +66.7]
30% 退化 − 扩展数据	+0.0	[+0.0, +0.0]
50% 退化 − 扩展数据	+0.0	[+0.0, +0.0]

区间按患者 / 图像关联组进行 2,000 次配对重抽样，比较同一张照片在两组模型中的阈值判断。本轮使用一个训练种子和 12 张正例，区间描述病例抽样变化。退化组与扩展无退化组在这 12 张上的判断完全一致，因此抽样差异区间为零；新病例上的差异仍需更大的真实质量样本评价。

另外按图像身份哈希选择同一批 384 张规则开发原图，其中 146 张正例、238 张阴性，分别施加参考 512 像素视野半径 2 的失焦和曝光乘数 0.70。表中每格是漏诊数量 / 误报数量，分别基于 146 张正例和 238 张阴性，以 0.5 为展示阈值；每张原图及其两个变体属于同一个病例观察。

条件	原数据：漏诊 / 误报	扩展数据	30% 退化	50% 退化
原图	30 / 16	28 / 20	21 / 13	23 / 14
轻度失焦	55 / 10	3 / 104	36 / 23	28 / 19
曝光乘数 0.70	39 / 13	23 / 28	26 / 17	29 / 18

扩展无退化组在失焦正例上漏诊 3/146 张，同时误报 104/238 张阴性，显示模糊图分数整体上移。30% 和 50% 退化组的误报分别降为 23/238 和 19/238，漏诊增加为 36/146 和 28/146。真实低质量阳性结果见前表；真实低质量阴性是下一轮的补充重点。PAPILA、ACRIMA、HYGD 及其余保留测试集将在模型和复核规则确定后评价。

模型选择的补充检查

训练过程中，HRF 仅 4 张验证图的一次排序变化就会改变来源 AUROC 平均值，使扩展数据组选中了第 300 次更新的权重。针对这个已观察到的问题，本次增加预算结束权重的开发评价，直接比较四组第 1,200 次更新，不改动原选模规则或选中权重。以下结果均来自同一规则开发集。

方案（第 1,200 次更新）	ODIR AUROC	AIROGS AUROC	KEH AUROC	真实低质量漏诊	合成失焦误报
原数据	0.9712	0.9687	0.6627	5/12	10/238
扩展数据	0.9315	0.9551	0.9333	0/12	68/238
扩展 + 30% 退化	0.9281	0.9583	0.9321	0/12	23/238
扩展 + 50% 退化	0.9404	0.9593	0.9368	0/12	19/238

该表与前面的选中权重结果分开保存，用于判断原有来源排序的下降有多少来自较早选模。下一轮应预先以具有足够正负例的主要来源设定选择标准，增加随机种子和更新预算，保留原图与真实低质量病例的检出、特异度和概率误差，然后锁定分类阈值及质量引导复核规则。

本轮数据扩展的主要观察为：同一 1,200 次更新预算下，KEH 开发 AUROC 从 0.6627 提高到 0.9333，真实低质量开发正例的展示阈值漏诊从 5/12 减少到 0/12。50% 退化将扩展模型的 ODIR AUROC 从 0.9315 提高到 0.9404，仍低于原数据对照的 0.9712；三个扩展组均检出这 12 张低质量阳性。下一轮需处理原有来源的排序和阈值表现，并补充真实低质量病例比较退化的额外效果。

同预算的合成失焦评价中，50% 退化将扩展原图模型的阴性误报从 68/238 降低到 19/238，正例漏诊从 18/146 变为 28/146。该变化明确呈现了误报减少与漏诊增加的关系；下一轮将结合真实低质量阴性，评价固定筛查阈值下的表现。

代码、证据和复现

数据整合审计 ·退化方法审计 ·冻结清单核验 ·完整对照结果 ·预算结束权重检查 ·四组配置 ·启动脚本

已完成的目录保留 best.pt、last.pt、逐步损失、验证曲线、原图和压力版本的开发预测，以及退化参数记录。配置、初始化、数据清单、发布信息和训练模块共同绑定到权重指纹；恢复时检查一致性。重新运行启动脚本会核查已完成预算，保留本轮产物。更改训练预算或设计时建立新配置和输出目录。